

A spectral grouping-based deep learning model for haze removal of hyperspectral images

Xiaofeng Ma, Qunming Wang *, Xiaohua Tong

摘要

雾霾污染是光学遥感图像 (包括高光谱图像 HSI) 中常见的问题, 它会扭曲土地覆盖物体的光谱特征。在过去的几十年里, 虽然已经开发了许多除霾解决方案, 但很少有研究集中在高光谱图像的除霾上。此外, 这些方法大多不能充分挖掘 HSI 在雾霾去除中的丰富光谱信息。针对这一问题, 本文提出了一种基于数据驱动的 HSI 雾霾去除方法。具体来说, 我们设计了一个光谱分组网络 (SG-Net) 来充分利用重建过程中各个光谱波段的有用信息。为了便于构建雾霾图像与相应的雾霾清晰图像之间的关系, 本文提出的 SG-Net 首先基于谱内相关性将每个高光谱图像划分为几个谱子集。然后, 将这些子集与多个分支并行卷积, 进行特征提取。在此基础上, 设计了一种新型的注意块, 将相邻的分支连接起来进行特征传输, 可以提取每个子集的有用信息 (如较长波段的未污染信息), 并协助重构高光谱图像。

关键词: 深度学习; 高光谱图像; 云雾

1 引言

遥感影像可以用不同波长的光谱波段表现地表覆被物的物理特征, 为地球观测提供了新的前景。具体来说, 高光谱图像 (HSIs) 可以提供光谱连续剖面 (即光谱曲线), 因为它记录了从可见光到红外光谱的数百个光谱波段。因此, 高光谱图像在农业管理^{[1][2]}中得到了广泛应用, 环境监测^{[3][4][5]}和军事建设^{[6][7]}。然而, 由于大气粒子的散射效应和吸收现象, 光学遥感图像, 包括高光谱图像, 通常会受到雾霾污染^[8]。因此, 在模糊像素中, 光谱曲线会发生变形。因此, 高光谱图像的准确识别不可避免地受到影响。

2 相关工作

2.1 模型驱动方法

一般来说, 去除雾霾是一个不适定的问题。朦胧图像通常由未知的全球大气光和透射图^[9]确定。在过去的几十年里, 各种消除雾霾的解决方案已经提出。一些研究人员使用了不同的先验或假设来去除雾霾。^[10]利用暗信道先验 (DCP) 计算传输。^[11]使用了雾霾清晰图像的局部色线来生成去除雾霾的传输。此外, 应用颜色衰减先验^[12]来估计雾清图像。非局部雾线先验^[13], 从朦胧和无雾图像统计, 也可以实现除雾。最近, 采用区域线先验法^[14]去除雾霾。虽然这些基于假设的方法在特殊情况下可以产生可接受的结果, 但对于各种雾霾污染, 不同的手工先验可能不具有代表性。此外, 雾霾去除问题可以转化为图像增强问题^[15]。具体来说, 在去除雾霾的过程中, 雾霾图像的退化模型和先验信息是不需要的。然而, 该图像增强方法不适合重度雾霾。上述方法都是模型驱动的方法, 要么需要各种手工制作的假设作为先验条件, 要么不适合各种情况。

由于自然图像与遥感图像的相似性 (如均含有 RGB 波段), 一方面, 几种自然图像去雾方法具有遥感图像去雾的潜力。另一方面, 遥感图像的特征 (如空间背景、光谱维度和大气环境) 限制了其潜力。^[16]对多光谱图像甚至大气效果使用暗物体减法。暗物减法也适用于雾霾厚度图估计^[17]。卷云波段与 Landsat-8 OLI 可见光或红外波段之间的线性相关性^[18]可作为雾霾去除的先验。^[19]修改了 DCP 以去除遥感图像的雾霾。此外, DCP 可以与球模型集成^[20]用于多光谱雾霾去除。然而, 由于 HSI 中有数百个光谱波段, 上述方法不适用于 HSI 雾霾的去除。一般来说, 雾霾污染与光谱波长高度相关, 波长越长, 雾霾污染越强, 反之亦然。基于相关性, 可以通过融合 HSI 中的雾霾短波红外波段^[21]来恢复雾霾可见光波段。然而, 结果依然是雾霾。目前, 已经构建了 HSI 雾霾去除的雾模型^[22]。具体而言, 雾模型表明, 雾霾指数中的每个雾分量都可以看作是雾丰度和雾强度图的乘积。雾丰度的估计依赖于同一物体在霾和无霾条件下的反射率差。然而, 由于不同的假设或先验, 这些模型驱动的方法可能难以用于不同的雾霾条件或卫星图像恢复。

2.2 数据驱动方法

数据驱动方法可以从各种任务的训练样本中充分探索内部特征^{[23][24]}。^[25]使用随机森林来估计具有几种与雾霾相关特征的传输。由于高维数据中复杂结构的能力, 神经网络^[26]在解决人工智能问题方面取得了进展。^[27]设计了一个 DehazeNet 来估计每个像素的传输。此外, 采用多尺度卷积神经网络 (MSCNN) 进行传输估计^[28]。这些方法不能直接生成无霾图像, 需要根据退化模型进行后处理才能生成去雾图像。此外, 额外的后处理步骤将带来意想不到的错误。利用神经网络直接学习朦胧图像和霾清图像之间的相关性^[29]可以减少误差。^[30]设计了一种卷积神经网络来融合不同的脱雾网络输出以去除雾霾。快速发展的神经网络方法也被广泛应用于遥感图像的雾霾去除。为 Landsat-8 OLI 图像雾霾去除构建了残差对称级联网络 (RSC-Net)^[31]。此外, 神经网络可以与去除雾霾的物理模型集成^[32]。然而, 这两种方法都是用真实的雾霾/雾霾清晰图像对训练的。显然, 雾霾图像与相应参考图像之间的土地覆盖变化会影响雾霾去除精度。为了克服这个问题, 一个合理的解决方案是实施雾霾模拟策略来准备训练图像。^[33]在训练样本模拟时, 同时考虑了雾霾条件下的颗粒大小和颗粒浓度。基于足够的合成样本,^[34]结合 U-Net 和 Slope-Net 来估计雾霾厚度图和每个波段的相应系数来进行除霾。多尺度的空间信息对除霾^[35]也很有用。此外, 条件生成对抗网络可以通过整合合成孔径雷达 (SAR) 图像^[36]产生可靠的除霾结果。

3 本文方法

在我们的研究中采用了深度学习策略, 因为它在不同的数据驱动方法之间具有高效的高级特征表示。然而, 当深度学习应用于 HSI 雾霾去除时, 出现了两个问题。首先, 由于不同传感器的波长覆盖范围不同, 成对训练样本难以收集。其次, 由于不同光谱波长的雾霾污染变化 (波长较短的波段通常对雾霾更敏感, 反之, 波长较长的波段对雾霾更稳健) 以及不同波段的光谱变化较大, 将所有 HSI 波段包括在一起很难构建雾霾图像与对应的雾霾清晰图像之间的关系。这些问题也影响了用于 HSI 雾霾去除的数据驱动方法, 特别是深度学习方法的发展。

3.1 本文方法概述

在我们的研究中，在基于 SGNet 的数据驱动除霾方法中考虑了 HSI 的光谱相关性。具体来说，通过光谱分组（SG）模块，基于光谱相关性，将原始的恒生指数分组为几个子集。也就是说，每个子集中的某个频段与相邻的频段高度相关。SG 模块被用来提取 HSI 的内部光谱相关性。随后，这些子集被输入到 SG-Net 中，以映射朦胧的 HSI 和朦胧的 HSI 之间的关系。在 SG-Net 中，如图 1所示，每个子集都是平行卷积的。此外，基于雾度和光谱波长之间的关系，设计了一个空间通道像素注意（SCPA）块来连接平行分支，以实现特征传输。此外，还提出了纵深全局残差学习（DGRL）来减轻网络训练。

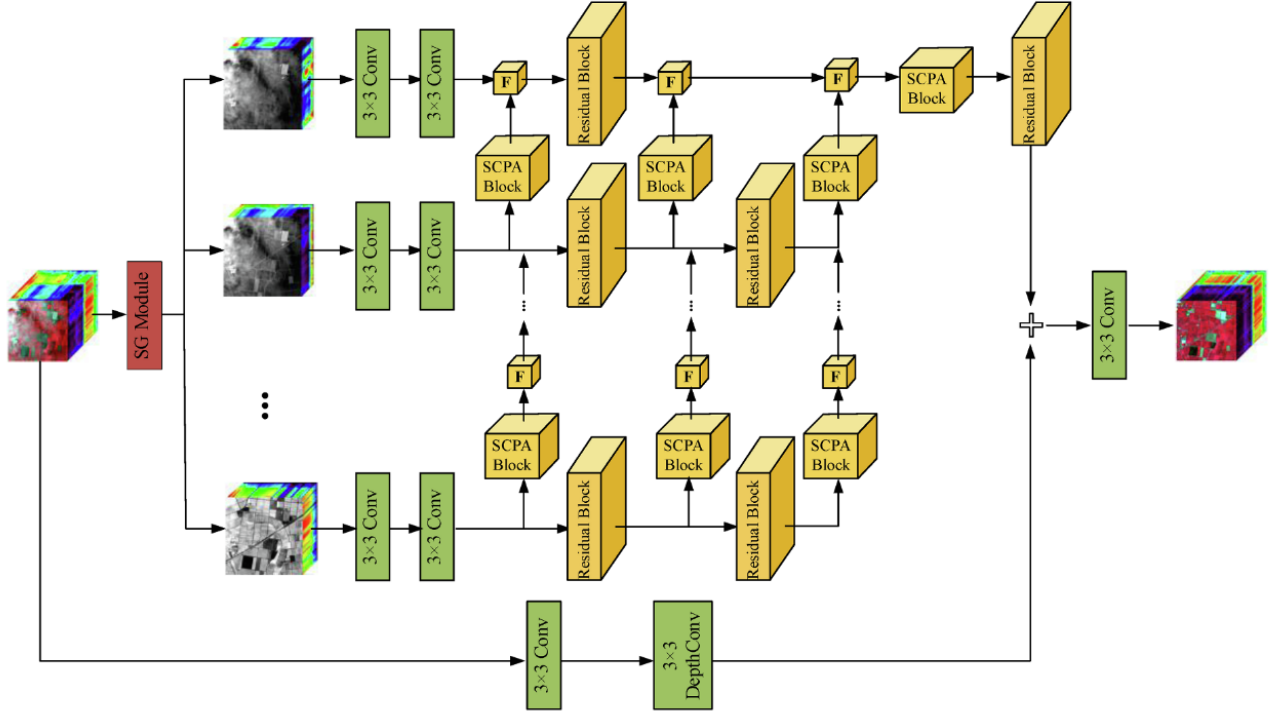


图 1: SG-Net 的架构

3.2 特征提取模块

SCPA block: 注意力机制用于为高级维度中的重要特征提供更多的权重，这已广泛用于不同领域。在我们的研究中，我们整合了三个不同的注意力模块，从较长的波长子集转移有用的特征，如图 2所示。首先，应用空间注意模块来关注模糊区域。具体来说，使用了一个 3×3 的卷积层，然后是一个并行卷积模块，滤波器大小分别为 3×3 和 5×5 。我们应用连接策略来整合这些特征，然后是一个 7×7 的卷积层进行进一步的特征提取。值得注意的是，这些层使用一个过滤器来实现空间注意力。随后，使用 sigmoid 函数来激活特征图。另外，一个乘积连接被应用于残差学习。在空间注意模块的尾部，采用了一个滤波大小为 3×3 的卷积层。其次，我们使用通道注意来提炼 HSI 中频谱带之间的内在相关性。从空间注意模块中提取的特征被输入到全局平均池（GAP）和全局平均池（GMP）中进行特征提取。随后，一个滤波数为 C/r （ C 表示特征通道数， r 为还原率）的 1×1 卷积层被用于激励。然后，我们使用另一个 1×1 的卷积层，用 C 个滤波器进行特征增强，然后用一个 sigmoid 激活函数。之后，采用像素加法进行特征整合。此外，还采用了类似的乘积残差学习。最后，像素注意力可用于提高特征表示能力并减少计算负荷，这适用于 HSI。具体来说，采用 1×1 卷积层作为残差连接。由于不同类型的注意力模块的结合，SCPA 块可以进一步探索子集之间的关联性，以达到消除雾霾的目的。

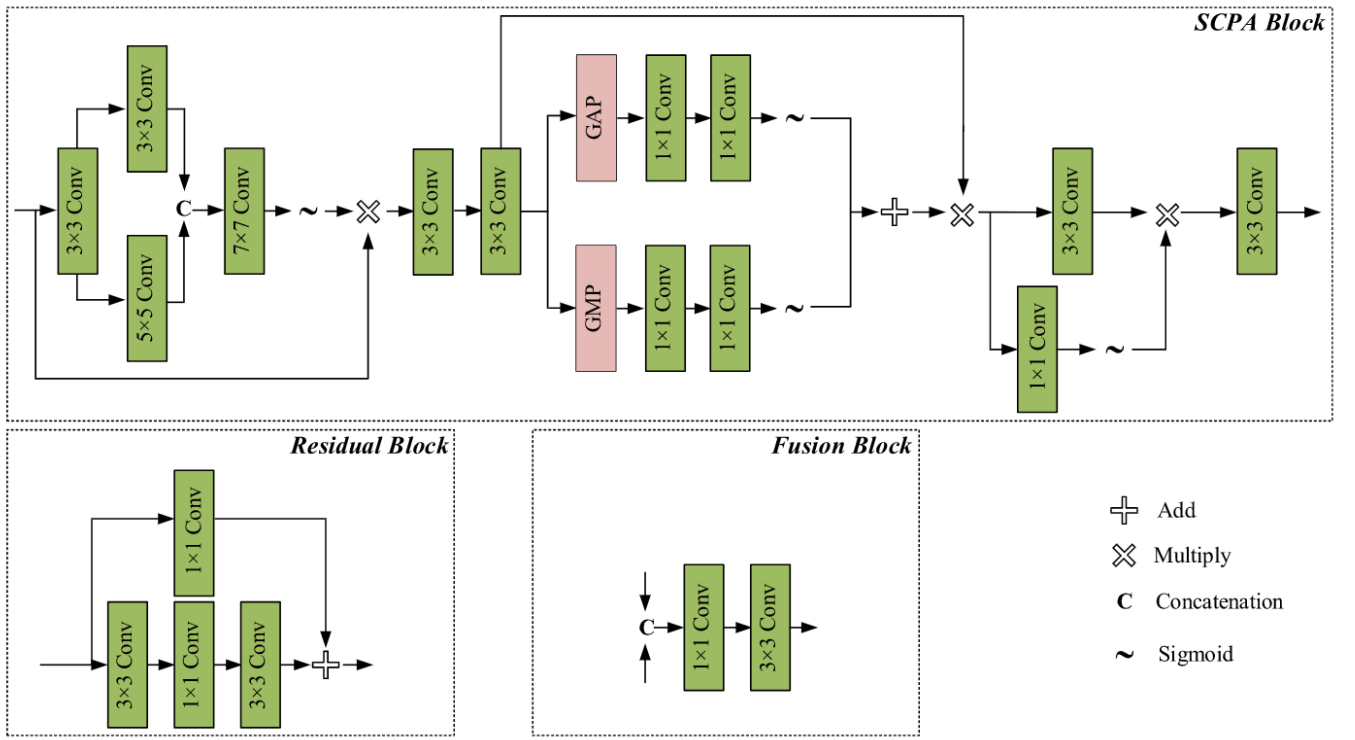


图 2: 图 1 中提议的 SG-Net 的不同块

Residual block: 由于遥感图像的空间内容复杂，采用了不同滤波器大小的基本块。如图 2 所示，残差块包含两种类型的卷积层。在主流中，我们使用三个卷积层进行特征提取，滤波器大小为 3×3 、 1×1 和 3×3 。此外，残差流采用 1×1 卷积层。提取的特征由像素级加法算子集成。

Fusion block: 为了融合从不同子集中提取的特征，提出了一种融合块。具体来说，我们使用连接策略将输入特征集成到通道维度中。接下来，连接的特征由两层卷积，大小为 1×1 和 3×3 。

DGRL: 残差连接已被用于各种架构以促进训练。在我们的研究中，为此目的提出了一种 DGRL 策略，它是残差学习的推导。具体来说，使用滤波器大小为 3×3 的卷积层来提取模糊 HIS 的浅层特征。接下来，我们使用 3×3 深度卷积层进行进一步特征提取。原因是，与普通卷积层相比，深度卷积层可以生成参数较少的足够特征图。显然，DGRL 策略可以减少计算负载并适合 HIS。最后，应用滤波器大小为 3×3 像素的卷积层将相关的去噪特征转换为清晰的图像。需要注意的是，该层的过滤器数量由输入 HIS 的带状数量决定。

3.3 损失函数定义

我们使用均方误差 (MSE) 作为损失函数。方程表述为：

$$MSE = ||X - \hat{X}||^2$$

其中 X 表示恢复的 HSI， \hat{X} 是相应的雾霾清晰的 HSI。

4 复现细节

4.1 与已有开源代码对比

复现的论文没有公开源代码。由于清晰的高光谱图像以及其对应的有云雾的高光谱图像收集比较困难，也很少有公开的数据集使用。所以我们使用清晰的高光谱图像模拟生成对应应有云雾的图像，构成样本对训练模型。本次复现实验共使用 384 对图像，其中 352 对作训练集，32 对作测试集，部分

训练样本如图 3所示




图 3: 清晰的高光谱图像以及对应的合成的有云雾的高光谱图像

4.2 实验环境搭建

Pytorch 1.13.1

CUDA Version:11.7

GPU:NVIDIA A40

4.3 创新点

为了充分利用每个带中的有用信息，所提出的 SG-Net 方法基于谱相关性（例如，谱相关系数图）将 HSI 分组到几个子集中。然后，一种新颖的 SG-Net 架构将这些子集并行卷积以进行特征提取。同时，设计了一个新颖的注意力块来连接每个子集以进行特征传输。此外，为 HSI 网络设计了一种新颖的全局残差学习。将较长波长带的有用信息（例如，未污染的信息）进一步结合在一起，以帮助恢复 HIS。根据不同波段的相关系数对波段进行分组，对不同组的数据并行处理。光谱变化已被考虑，以促进雾霾图像和对应的雾霾-清晰图像之间的关系构建。据我们所知，几乎没有研究考虑到 HSI 除霾的光谱变化。此外，较长波长波段的有用信息（如未受污染的信息）被进一步整合在一起，以协助恢复 HSI。本文为 HSI 的除霾提供了一个新的思路，可以指导这一课题的未来研究（即在此指导下有可能开发各种方法）

5 实验结果分析

本次实验使用 384 对图像，其中 352 对用作训练，32 对用作测试集。在一张英伟达 A40 显卡上共训练 200 个 epochs, batch size 为 32。使用 Adam 优化器。本次论文复现的模型效果图如图 4所示，在较后的云雾区域中，能将云雾去除。但同时也会对原本清晰的图像产生重影。




图 4: 测试集上的去云效果展示

6 总结与展望

复现这篇论文最大的感受就是第一个完整地跑了一次深度模型。亲手制作训练集，为清晰的高光谱图像添加云雾。从零开始学习 Pytorch 框架，从安装软件到成功将模型跑起来，这一学习下来自己收获良多。但本次复现还是存在不少问题，例如效果会对原本清晰的高光谱图像产生重影。在接下来的科研工作中，我会继续向高光谱去云雾方向努力！争取在高光谱去云雾方向有所收获。

参考文献

- [1] MCCANN C, REPASKY K S, LAWRENCE R L, et al. Multi-temporal mesoscale hyperspectral data of mixed agricultural and grassland regions for anomaly detection[J]. Isprs Journal of Photogrammetry and Remote Sensing, 2017.
- [2] JÄNICKE C, OKUJENI A, COOPER S, et al. Brightness gradient-corrected hyperspectral image mosaics for fractional vegetation cover mapping in northern California[J]. Remote Sensing Letters, 2020.
- [3] LESSER M P, MOBLEY C D. Bathymetry, water optical properties, and benthic classification of coral reefs using hyperspectral remote sensing imagery[J]. Coral Reefs, 2007.
- [4] MA S, TAO Z, YANG X, et al. Bathymetry Retrieval From Hyperspectral Remote Sensing Data in Optical-Shallow Water[J]. IEEE Transactions on Geoscience and Remote Sensing, 2014.

- [5] DUAN P, LAI J, KANG J, et al. Texture-aware total variation-based removal of sun glint in hyperspectral images[J]. *Isprs Journal of Photogrammetry and Remote Sensing*, 2020.
- [6] CHANG C I. Hyperspectral Target Detection: Hypothesis Testing, Signal-to-Noise Ratio, and Spectral Angle Theories[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2021.
- [7] BIOUCAS-DIAS J M, PLAZA A, DOBIGEON N, et al. Hyperspectral Unmixing Overview: Geometrical, Statistical, and Sparse Regression-Based Approaches[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2012.
- [8] RichterRudolf. Atmospheric correction of satellite data with haze removal including a haze/clear transition region[J]. *Computers & Geosciences*, 1996.
- [9] NARASIMHAN S G, NAYAR S K. Contrast restoration of weather degraded images[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2003.
- [10] HE K, SUN J, TANG X. Single image haze removal using dark channel prior[J]. *computer vision and pattern recognition*, 2009.
- [11] FATTAL R. Dehazing Using Color-Lines[J]. *ACM Transactions on Graphics*, 2014.
- [12] ZHU Q, MAI J, SHAO L. A Fast Single Image Haze Removal Algorithm Using Color Attenuation Prior [J]. *IEEE Transactions on Image Processing*, 2015.
- [13] BERMAN D, TREIBITZ T, AVIDAN S. Non-local Image Dehazing[J]. *computer vision and pattern recognition*, 2016.
- [14] JU M, DING C, GUO C, et al. IDRLP: Image Dehazing Using Region Line Prior[C]// . 2022.
- [15] CHO Y, JEONG J, KIM A. Model-Assisted Multiband Fusion for Single Image Enhancement and Applications to Robot Vision[C]// . 2018.
- [16] GEMINI N. An Improved Dark-Object Subtraction Technique for Atmospheric Scattering Correction of Multispectral Data*[J]. *Remote Sensing of Environment*, 1988.
- [17] MAKARAU A, RICHTER R, MÜLLER R, et al. Haze Detection and Removal in Remotely Sensed Multispectral Imagery[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2014.
- [18] XU M, JIA X, PICKERING M R. Automatic cloud removal for Landsat 8 OLI images using cirrus band [J]. *international geoscience and remote sensing symposium*, 2014.
- [19] PAN X, XIE F, JIANG Z, et al. Haze Removal for a Single Remote Sensing Image Based on Deformed Haze Imaging Model[J]. *IEEE Signal Processing Letters*, 2015.
- [20] LI J, HU Q, AI M. Haze and Thin Cloud Removal via Sphere Model Improved Dark Channel Prior[J]. *IEEE Geoscience and Remote Sensing Letters*, 2019.
- [21] LI J, SHEN H, LI H, et al. Radiometric quality improvement of hyperspectral remote sensing images: a technical tutorial on variational framework[J]. *Journal of Applied Remote Sensing*, 2021.

- [22] KANG X, FEI Z, DUAN P, et al. Fog Model-Based Hyperspectral Image Defogging[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021.
- [23] SAGAN V, MAIMAITIJANG M, PAHEDING S, et al. Data-Driven Artificial Intelligence for Calibration of Hyperspectral Big Data[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021.
- [24] SVENDSEN D H, PILES M, MUÑOZ-MARÍ J, et al. Integrating Domain Knowledge in Data-Driven Earth Observation With Process Convolutions[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021.
- [25] TANG K, YANG J, WANG J. Investigating Haze-Relevant Features in a Learning Framework for Image Dehazing[J]. computer vision and pattern recognition, 2014.
- [26] LECUN Y, BENGIO Y, HINTON G E. Deep learning[J]. Nature, 2015.
- [27] CAI B, XU X, JIA K, et al. DehazeNet: An End-to-End System for Single Image Haze Removal[J]. IEEE Transactions on Image Processing, 2016.
- [28] REN W, LIU S, ZHANG H, et al. Single Image Dehazing via Multi-scale Convolutional Neural Networks[J]. european conference on computer vision, 2016.
- [29] BOYI L, XIULIAN P, ZHANGYANG W, et al. AOD-Net: All-in-One Dehazing Network[J]. IEEE Conference Proceedings, 2017.
- [30] PARK J, HAN D K, KO H. Fusion of Heterogeneous Adversarial Networks for Single Image Dehazing [J]. IEEE Transactions on Image Processing, 2020.
- [31] LI W, LI Y, DI C, et al. Thin Cloud Removal with Residual Symmetrical Concatenation Network[J]. international geoscience and remote sensing symposium, 2019.
- [32] LI J, WU Z, HU Z, et al. Thin cloud removal in optical remote sensing images based on generative adversarial networks and physical model of cloud distortion[J]. Isprs Journal of Photogrammetry and Remote Sensing, 2020.
- [33] GUO J, YANG J, YUE H, et al. RSDehazeNet: Dehazing Network With Channel Refinement for Multispectral Remote Sensing Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021.
- [34] ZI Y, XIE F, ZHANG N, et al. Thin Cloud Removal for Multispectral Remote Sensing Images Using Convolutional Neural Networks Combined With an Imaging Model[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021.
- [35] CHEN X, LI Y, DAI L, et al. Hybrid High-Resolution Learning for Single Remote Sensing Satellite Image Dehazing[J]. IEEE Geoscience and Remote Sensing Letters, 2021.
- [36] HUANG B, LI Z, YANG C, et al. Single Satellite Optical Imagery Dehazing using SAR Image Prior Based on conditional Generative Adversarial Networks[J]. workshop on applications of computer vision, 2020.